Tratamento e Análise de Dados - Nivelamento LACEDA

Daniel de Oliveira
alves.d@ufba.br

I. Introdução

Esse relatório tem como intuito analisar um conjunto de dados fictícios do departamento de Recursos Humanos de uma empresa de advocacia, de forma que os dados passem por tratamento, caso aplicável, e identificar os fatores mais presentes em funcionários desligados da empresa. A manipulação e plotting foram realizadas no ambiente Jupyter Notebook com auxílio das bibliotecas *pandas, NumPy e seaborn.*

II. Análise inicial e Polimento de dados

Os dados estavam contidos em três arquivos .csv diferentes, listando funcionários, filiais e departamentos. A base de dados dos funcionários possuía alterações nos valores que dificultariam uma análise uniforme e precisou passar pelo seguinte polimento para limpar os ruídos, erros de digitação e formatação e omissões.

- Coluna **"nome"**: Removido o **id_colaborador**, presente nos finais dos nomes.
- Coluna **"genero"**: Corrigidas as iterações onde "Feminino"estava abreviado para "Fem".
- Coluna **"salario_base"**: Padronização dos valores de salário para o formato decimal.
- Colunas **data_admissao e data_promocao**: Padronização dos formatos de data para YY-MM-DD (datetime).

Com o tratamento das inconsistências, Os dados estavam contidos em três arquivos .csv diferentes, listando funcionários, filiais e departamentos. Por meio de uma *merge* (mescla) entre essas três bases de dados por junção via *left join* nas chaves **id_departamento e id_filial**, foi obtido o dataframe dadosUnificados, que foi o alvo das análises de evasão.

III. Engenharia de Dados

Nessa etapa, para facilitar as futuras análises, alteramos a variável **home_office** que antes possuía um valor booleano para valores *string*, para melhor clareza nos resultados. Foram criadas também duas novas variáveis:

- **inativo**: Com valor 0 para funcionários ativos, 1 caso desligados.
- **faixa_horas_extras**: Quantidade de horas extras por funcionário dividida em intervalos de 10 horas para maior concisão na análise.
- **faixa_satisfacao**: Seguindo a lógica do item anterior, valor de satisfação de cada funcionário dividido em intervalos de 0.5 pontos para maior concisão na análise.

Após esses ajustes, o arquivo .csv estava finalizado para análise posterior.

IV. Análise dos dados

Nessa análise, foram investigados os fatores que poderiam ter maior influência na evasão laboral utilizando as métricas obtidas da base de dados.

A. Desligamento por Filial

Do mapeamento, obtivemos os seguintes resultados, em ordem decrescente:

1) **Rio de Janeiro:** $29,52\%$
2) **São Paulo:** $28,90\%$
3) **Salvador:** $26,45\%$
4) **Belo Horizonte:** $23,72\%$

Dado o equilíbrio entre esses valores, já que o desvio padrão é de aproximadamente $2,64$, esse fator não demonstra discrepância.

B. Desligamento por Gênero

Do mapeamento, obtivemos os seguintes resultados, em ordem decrescente:

1) **Não-binário:** $30,37\%$
2) **Feminino:** $26,01\%$
3) **Masculino:** $25,35\%$

O fator de gênero aparenta levemente mais parcial, mas não o suficiente para indicar algo concreto, já que o desvio padrão continua baixo, de aproximadamente $2,73$.

C. Desligamento por Horas

Do mapeamento, obtivemos os seguintes resultados, ordenados crescentemente considerando as faixas de horas:

1) **0-10h:** $21,43\%$
2) **11-20h:** $20,25\%$
3) **21-30h:** $28,57\%$
4) **31-40h:** $43,59\%$
5) **>41h:** $43,51\%$

A quantidade de horas extras é um fator bem considerável, com um desvio padrão de aproximadamente $11,48$. A taxa de evasão cresce proporcionalmente, o que sugere que jornadas de trabalho mais longas levam a mais casos de desligamentos.

D. Desligamento por Nível

Do mapeamento, obtivemos os seguintes resultados, ordenados de forma decrescente:

1) **Pleno** $47,15\%$
2) **Júnior** $18,95\%$
3) **Sênior** $15,58\%$
4) **Sócio** $0,00\%$

Com um desvio padrão de $19,64$, essa métrica é a mais alarmante, já que cerca de metade de todos os funcionários de nível pleno da empresa passam pelo processo de desligamento. Percebe-se também a evasão nula dos sócios, ou seja, todos os sócios da empresa estão ativos.

E. Desligamento por Departamento

Do mapeamento, obtivemos os seguintes resultados, ordenados de forma decrescente:

1) **Trabalhista** $43,53\%$
2) **Tributário** $27,47\%$
3) **Civil** $18,54\%$
4) **Corporativo** $17,01\%$

O setor trabalhista é o que possui a taxa de evasão mais discrepante, seguido pelo setor tributário. Os outros dois setores não possuem uma diferença entre suas taxas de evasão, o que coloca o desvio padrão em aproximadamente $12,17$.

F. Desligamento por Modo

Do mapeamento, obtivemos os seguintes resultados, ordenados de forma decrescente:

1) **Home-Office** $27,92\%$
2) **Presencial** $26,75\%$

Com o menor desvio padrão dos fatores avaliados, com valor aproximado de de $0,83$, esse é o fator que menos impacta diretamente na taxa de evasão.

G. Desligamento por Satisfação x Nível

Tabela I: Taxa de evasão (%) por faixa de satisfação e nível hierárquico.

Faixa de Satisfação	Júnior	Pleno	Sênior	Sócio
1.0–1.5	54.17%	60.00%	8.33%	0.00%
1.5–2.0	54.17%	44.00%	0.00%	0.00%
2.0–2.5	60.00%	0.00%	50.00%	0.00%
2.5–3.0	0.00%	100.00%	0.00%	0.00%
3.0–3.5	0.00%	42.11%	50.00%	0.00%
3.5–4.0	0.00%	42.86%	14.29%	0.00%
4.0–4.5	0.00%	30.95%	13.64%	0.00%
4.5–5.0	0.00%	69.70%	9.09%	0.00%

V. Conclusão

Nessa análise de dados, podemos verificar os maiores fatores que os funcionários desligados possuem em comum, pois estão mais concentrados em:

- **Júniores com satisfação baixa (< 2,5).**
- **Funcionários de nível pleno.**
- **Funcionários do setor trabalhista.**
- **Funcionários com mais de 30 horas extrass mensais trabalhadas.**